

SISTEM DETEKSI STRES PORTABEL PADA PENGEMUDI MENGGUNAKAN DECISION TREE BERBASIS SINYAL PHOTOPLETHYSMOGRAM

Alifa Azwadina Fuad¹, Edita Rosana Widasari^{*2}

^{1,2}Universitas Brawijaya, Malang

Email: ¹alifaazwadinaf@student.ub.ac.id, ²editarosanaw@ub.ac.id

^{*}Penulis Korespondensi

(Naskah masuk: dd mmm yyyy, diterima untuk diterbitkan: dd mmm yyyy)

Abstrak

Stres merupakan kondisi psikofisiologis yang dapat mengganggu konsentrasi dan kemampuan pengemudi dalam mengendarai kendaraan, yang akan mengakibatkan meningkatnya risiko kecelakaan lalu lintas. Oleh karena itu, sistem deteksi stres portabel pada pengemudi menjadi langkah penting untuk mendukung keselamatan berkendara pada pengemudi. Penelitian ini bertujuan untuk mengembangkan sistem deteksi stres portabel berbasis sinyal *Photoplethysmogram* (PPG) menggunakan fitur *Average of NN Intervals* (AVNN) dan *Standard Deviation of NN Intervals* (SDNN) serta metode klasifikasi *machine learning Decision Tree*. Sistem ini menggunakan sensor MAX30102 untuk mengakuisisi sinyal PPG secara *real-time*, dengan hasil deteksi stres yang ditampilkan pada layar *Organic Light Emitting Diode* (OLED) dan dilengkapi dengan indikator buzzer serta Light Emitting Diode (LED). Pengujian sistem menunjukkan bahwa metode *Decision Tree* dengan fitur AVNN dan SDNN mampu mencapai akurasi klasifikasi stres sebesar 80% berdasarkan data dari lima subjek uji. Selain itu, sistem ini memiliki rata-rata waktu komputasi 2,6 detik, mengindikasikan efisiensi sistem yang baik. Pengujian keseluruhan sistem membuktikan bahwa perangkat portabel ini bekerja dengan andal sesuai skenario yang dirancang, sehingga berpotensi digunakan sebagai alat deteksi stres portabel bagi pengemudi.

Kata kunci: *Stres, Photoplethysmogram (PPG), Average of NN Interval (AVNN), Standard Deviation of NN Interval (SDNN), Decision Tree*

PORTABLE STRESS DETECTION SYSTEM FOR DRIVERS USING DECISION TREE BASED ON PHOTOPLETHYSMOGRAM SIGNALS

Abstract

Stress is a psychophysiological condition that can interfere the driver's concentration and ability to drive a vehicle, which will increase the risk of traffic accidents. Therefore, a portable stress detection system for drivers is an important step to support driving safety for drivers. This study aims to develop a portable stress detection system based on Photoplethysmogram (PPG) signals using the Average of NN Intervals (AVNN) and Standard Deviation of NN Intervals (SDNN) features and the Decision Tree machine learning classification method. This system uses the MAX30102 sensor to acquire PPG signals in real-time, with stress detection results displayed on the Organic Light Emitting Diode (OLED) screen and equipped with buzzer and Light Emitting Diode (LED) indicators. System testing shows that the Decision Tree method with AVNN and SDNN features is able to achieve a stress classification accuracy of 80% based on data from five test subjects. In addition, this system has an average computation time of 2.6 seconds, indicating good system efficiency. Overall system testing proves that this portable device works reliably according to the designed scenario, so it has the potential to be used as a portable stress detection tool for drivers.

Keywords: *Stress, Photoplethysmogram (PPG), Average of NN Interval (AVNN), Standard Deviation of NN Interval (SDNN), Decision Tree*

1. PENDAHULUAN

Salah satu faktor penyebab terjadinya kecelakaan lalu lintas yang mengakibatkan banyak

korban luka dan korban jiwa adalah stres saat berkendara. Stres dapat didefinisikan sebagai respons tubuh yang tidak spesifik terhadap kombinasi

tuntutan eksternal dan kekhawatiran internal (Mou, 2021). Hal ini juga sejalan oleh (Brown, et al., 2016) yang menyimpulkan bahwa stres sering kali menyebabkan kondisi psikofisik buruk yang dapat meningkatkan risiko kecelakaan hampir sepuluh kali lipat. Stres meningkatkan risiko kecelakaan dengan melemahkan kemampuan kognitif pengemudi, yang akan mengakibatkan menurunnya performa berkendara (Useche, Ortiz, & Cendales, 2017). Oleh karena itu, untuk mengurangi risiko kecelakaan dan meningkatkan keselamatan berkendara, perlu dibangun suatu sistem yang dapat mendeteksi stres pengemudi secara akurat.

Jumlah penduduk Indonesia diperkirakan mencapai 298,03 juta jiwa pada tahun 2030. Angka ini meningkat 1,01% dari jumlah penduduk pada tahun 2020 (BPS, 2023). Dampak meningkatnya jumlah penduduk berbanding lurus dengan meningkatnya kebutuhan penduduk termasuk kebutuhan akan transportasi. Semakin bertambahnya jumlah penduduk, maka semakin meningkat pula jumlah kendaraan bermotor dan kebutuhan fasilitas jalan raya sebagai penunjangnya. Salah satu permasalahan lalu lintas pada moda transportasi darat yang sering dihadapi oleh penduduk saat ini adalah bertambahnya jumlah kepemilikan kendaraan, namun masih terbatasnya sumber daya pengoperasian fasilitas arus lalu lintas yang sering mengakibatkan terjadinya kemacetan lalu lintas. Kondisi fasilitas yang terdapat di jalan raya yang tidak sebanding dengan banyaknya kendaraan juga akan berdampak pada tingkat kepadatan dan keramaian kendaraan di berbagai tempat, sehingga dapat menyebabkan kemacetan lalu lintas. Kemacetan juga menambah waktu yang diperlukan oleh seorang pengemudi untuk mencapai tujuannya, sehingga akan mempengaruhi lamanya mengemudi. Hal ini dapat menyebabkan terjadinya kelelahan yang dialami oleh pengemudi, menurunnya konsentrasi, stres, dan disiplin berlalu lintas pengemudi saat mengendarai kendaraannya karena ingin segera sampai di tujuan, sehingga pada akhirnya dapat menyebabkan terjadinya kecelakaan lalu lintas.

Sistem deteksi stres kepada pengemudi telah dikembangkan oleh penelitian terdahulu dengan penerapan *machine learning* menggunakan perangkat sensor fisiologis seperti *electrocardiogram* (ECG) dan *skin potential response* (SPR) (Zontone, 2022). Namun perangkat tersebut memiliki keterbatasan seperti tidak terdapat *feedback* langsung kepada pengemudi, memori yang tidak cukup, waktu komputasi tidak pasti, dan banyaknya perangkat yang melekat pada tubuh sehingga menimbulkan ketidaknyamanan pengguna (Zontone, 2022). Sehingga, perlu adanya perangkat *embedded system* yang terdapat *feedback* langsung pada pengemudi, mempunyai memori yang cukup, memiliki akurasi tinggi, dan waktu komputasi rendah guna mendeteksi stres secara *real-time*.

Beberapa penelitian menunjukkan bahwa stres dapat diukur melalui teknik pengukuran fisiologis seperti *Electrocardiogram* (ECG), *Photoplethysmography* (PPG), *Heart Rate Variability* (HRV), dan *Heart Rate* (HR) (Dobbs, 2019) (Valenti, 2023) (Barki, 2023). Teknik pengukuran ini dianggap sebagai teknik yang akurat untuk pencatatan sinyal biologis untuk mendeteksi stres. Selanjutnya, penelitian (Barki, 2023) juga membuktikan kualitas teknik pengukuran HRV berdasarkan sinyal PPG yang diperoleh dari perangkat sensor MAX30102. Hasil pengukuran HRV yang diperoleh dari sensor MAX30102 menunjukkan bahwa sistem yang menggunakan sinyal PPG mencapai akurasi 92,04%.

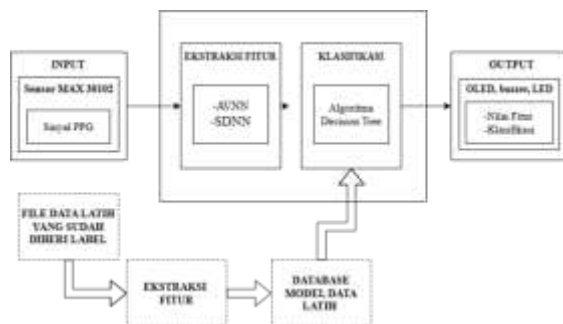
Selanjutnya, penelitian (Dalmeida, 2021) telah melakukan evaluasi statistik fitur HRV pada domain waktu, domain frekuensi, dan domain nonlinear untuk klasifikasi stres. Hasilnya, fitur yang efektif untuk mendeteksi stres adalah fitur HRV pada domain waktu yaitu *Average of NN Intervals* (AVNN) dan *Standard Deviation of NN intervals* (SDNN). Sedangkan parameter domain frekuensi tidak memberikan perbedaan signifikan antara kondisi stres dan non-stres, dan MLP dianggap sebagai algoritma terbaik untuk klasifikasi stres dan non-stres karena memiliki skor sensitivitas sebesar 80%. Akan tetapi, penelitian (Zainudin, 2021) menunjukkan bahwa *Decision Tree* (DT) mencapai hasil terbaik dengan akurasi 95% untuk klasifikasi kondisi stres dan non-stres berdasarkan HRV. Oleh karena itu, pada penelitian ini akan menggunakan kinerja *machine learning Decision Tree* karena dinilai menunjukkan akurasi yang tinggi terhadap perangkat *embedded system* yang diusulkan.

Dalam penelitian ini, diusulkan sebuah perangkat *embedded system* yang *low-cost*, portabel, tidak invasif, serta dapat melakukan deteksi stres pada pengemudi dan belum pernah dilakukan oleh penelitian terdahulu. *Embedded system* yang diusulkan menggunakan sensor MAX30102 yang diletakkan di jari tangan untuk akuisisi sinyal PPG dan kemudian diolah untuk mencari NN interval. Selanjutnya, menggunakan fitur HRV seperti AVNN dan SDNN berdasarkan nilai NN interval untuk mengetahui hasil deteksi stres berdasarkan kinerja *machine learning Decision Tree*. Keseluruhan proses *pre-processing* dan *processing* dilakukan pada perangkat mikrokontroler Arduino, kemudian hasil deteksi langsung dapat tertera pada layar *Organic Light Emitting Diode* (OLED) dan notifikasi dari buzzer dan *Light Emitting Diode* (LED). Hal ini merupakan solusi dari keterbatasan perangkat saat ini. Sehingga, perangkat yang diusulkan dapat menjadi perangkat *embedded system* yang *low-cost*, portabel, tidak invasif, memiliki akurasi tinggi, dan waktu komputasi rendah guna mendeteksi stres secara langsung. Implementasi metode *Decision Tree* dengan fitur AVNN dan SDNN diharapkan dapat menjawab rumusan masalah pada penelitian ini untuk

memperoleh nilai akurasi sistem yang tinggi untuk mendeteksi NN interval dalam mengukur detak jantung, mendapatkan hasil pembacaan sensor MAX30102 yang sesuai, memperoleh nilai akurasi sistem yang tinggi dalam mendeteksi stres menggunakan metode *Decision Tree* dengan fitur AVNN dan SDNN, serta waktu komputasi yang cepat agar perangkat ini dapat bermanfaat sebagai perangkat deteksi stres bagi pengemudi pada situasi kehidupan sehari-hari guna mengurangi faktor risiko kecelakaan di jalan raya.

2. SISTEM YANG DIUSULKAN

2.1 Gambaran Umum Sistem



Gambar 1. Skema Perancangan Sistem

Gambar 1 menggambarkan langkah awal dalam perancangan sistem, yaitu menyiapkan *data training* yang sudah diberi label dari dataset. Dataset yang digunakan berjudul *Stress Recognition in Automobile Drivers*, dataset ini dikumpulkan di Massachusetts Institute of Technology (MIT) oleh (Healey dan Picard, 2005), yang tersedia secara bebas di PhysioNet. Dataset ini terdiri dari kumpulan rekaman *multi-biosignal* parameter yang diperoleh dari 27 individu muda dan sehat, yang mencakup kondisi stres rendah, sedang, dan tinggi. Dari dataset tersebut diambil nilai *beat per minute* (BPM) untuk diberi label “Stres” dan “Tidak Stres”, kemudian melakukan ekstraksi fitur HRV seperti AVNN dan SDNN dan menyimpannya ke dalam *data training*. Total data latihan yang digunakan pada penelitian ini adalah 1.227 data yang terdiri dari 18 *drivers* dengan total rekaman selama 4.500 detik dan disegmentasi setiap 60 detik.

Selanjutnya membuat model pelatihan *machine learning Decision Tree* dengan pembagian 80% data latihan dan 20% data uji. Kemudian, hasil model klasifikasi tersebut menjadi tersebut diimplementasikan pada Arduino dan mengambil data baru sinyal PPG dari subjek menggunakan sensor MAX30102, kemudian dapat dilakukan tahap ekstraksi fitur, klasifikasi stres menggunakan algoritma *Decision Tree*, dan menampilkan nilai fitur serta hasil klasifikasi. Total data uji yang digunakan dalam penelitian ini adalah 30 data dimana 10 data termasuk dalam pengujian tingkat akurasi sistem untuk mendeteksi NN Interval dalam mengukur detak jantung dan kesesuaian hasil pembacaan sinyal PPG

pada sensor MAX30102 dan 20 data termasuk dalam pengujian tingkat akurasi sistem dalam mendeteksi stres menggunakan metode *Decision Tree* dengan fitur AVNN dan SDNN serta waktu komputasi sistem dalam mendeteksi stres terhadap pengemudi.

2.2 Teknik Pengumpulan Data

Penelitian ini akan menggunakan dataset yang akan menjadi *data training*, dataset dengan judul *Stress Recognition in Automobile Drivers* ini dikumpulkan di Massachusetts Institute of Technology (MIT) oleh (Healey dan Picard, 2005), yang dapat diakses tanpa batasan akses di PhysioNet. Dataset ini terdiri dari kumpulan rekaman *multi-biosignal* parameter yang diperoleh dari sukarelawan sehat, yang diambil saat mereka mengemudi di sekitar Boston, Massachusetts. Dataset ini tersedia dalam format waveform PhysioNet yang di dalamnya terdapat 18 *file .dat* dan 18 *file .hea* dengan *file* metadata *.txt*. Setiap *file biosignal .dat* berisi rekaman asli untuk sinyal ECG, EMG, GSR, HR, dan respirasi seperti yang ditunjukkan pada Gambar 2.



Gambar 2. Tampilan *multi-biosignal* pada dataset
Sumber: (Healey dan Picard, 2005)

Dikarenakan tujuan penelitian ini adalah mengklasifikasikan stres berdasarkan nilai HRV, *file* anotasi *beat* dibuat dari *file .m* menggunakan aplikasi WQRS di Physionet. Aplikasi ini bekerja dengan menemukan kompleks QRS dalam sinyal ECG dan menghasilkan file anotasi sebagai *output*. *File* anotasi ini digunakan untuk mengekstrak interval RR sesuai dengan durasi waktu menggunakan *toolkit* HRV PhysioNet. Fitur HRV seperti AVNN dan SDNN diekstraksi dari interval RR dengan membagi dataset menjadi beberapa segmen selama 60 detik. Fitur HRV ini kemudian dihitung dan dijadikan sebagai *data training*.


Selanjutnya, perlu mengembangkan model *machine learning* yang dapat mengklasifikasikan stres dari fitur HRV yang diperoleh dari pengukuran menggunakan sensor MAX30102. Untuk tujuan ini, data primer dikumpulkan langsung dari subjek penelitian dengan menggunakan perangkat simulasi mengemudi dengan nama *game*-nya yaitu “Euro Truck Simulator”. Pengumpulan data dilakukan dalam kondisi nyata, dimana subjek melakukan simulasi mengemudi di Laboratorium Robotika dan

Embedded System selama 40 menit dengan total 4 sesi mengemudi, dimana setiap sesi diberikan waktu selama 10 menit untuk berkendara sesuai dengan kondisi dan skenario jalan yang berbeda. Di setiap sesi juga akan dilakukan survei menggunakan kuesioner *Depression, Anxiety, and Stress Scales* (DASS) untuk mengetahui akurasi pengemudi tersebut benar-benar stres. Data yang nantinya akan diuji dan dianalisis terbagi menjadi 2 kelas yaitu stres dan tidak stres. Tahapan sesi pengambilan data menggunakan perangkat simulator mengemudi pada penelitian ini adalah sebagai berikut:

1. Jalan tol tanpa lalu lintas.
2. Jalan tol dengan lalu lintas.
3. Jalan perkotaan tanpa lalu lintas.
4. Jalan perkotaan dengan lalu lintas.

2.3 Photoplethysmogram (PPG)

Photoplethysmogram (PPG) adalah sinyal fisiologis yang diperoleh melalui *photoplethysmography*, sebuah teknik non-invasif yang menggunakan cahaya untuk mendeteksi perubahan volume darah dalam jaringan tubuh. Sinyal PPG dihasilkan ketika cahaya inframerah memancarkan sinarnya ke kulit, dan intensitas cahaya yang ditransmisikan diukur oleh fotodetektor (Liu, et al., 2020). Perubahan dalam intensitas cahaya yang terdeteksi mencerminkan variasi dalam volume darah, yang berkorelasi dengan denyut jantung (Esgalhado, 2022). Pada sinyal PPG, setiap gelombang detak jantung mencerminkan perubahan volumetrik darah di dalam pembuluh darah, dengan titik sistolik yang merupakan titik tertinggi pada gelombang sinyal PPG yang mewakili puncak tekanan darah saat jantung berkontraksi untuk memompa darah ke seluruh tubuh. Sedangkan titik diastolik merupakan titik terendah pada gelombang sinyal PPG yang mencerminkan tekanan darah minimum saat jantung dalam kondisi rileks. Gelombang sinyal PPG ditunjukkan pada Gambar 3.




Gambar 3. Sinyal *Photoplethysmogram* (PPG)
Sumber: (Nath, et al., 2018)

2.4 Normal-to-Normal (NN) interval

Normal-to-Normal (NN) interval adalah istilah yang merujuk pada interval waktu antara dua detak jantung berturut-turut yang berasal dari siklus normal.

Dalam analisis HRV, NN interval merupakan parameter penting karena menggambarkan fungsi sistem saraf otonom yang mengatur detak jantung. Dalam sistem deteksi stres berbasis sinyal PPG, NN interval dapat dihitung dengan mendeteksi puncak gelombang sistolik yang mencerminkan kondisi jantung yang sedang kontraksi. Sinyal PPG yang dipengaruhi oleh variasi volume darah memberikan pola gelombang yang dapat digunakan untuk menghitung interval antar puncak. Individu yang mengalami stres cenderung menunjukkan NN interval yang lebih pendek dan konsisten, hal ini mencerminkan penurunan variabilitas detak jantung (HRV), sedangkan individu yang tidak stres menunjukkan NN interval yang lebih panjang dan bervariasi (Liu, et al., 2020). NN interval ditunjukkan pada Gambar 4.



Gambar 4. *Normal-to-normal* (NN) interval
Sumber: (Gervasi, et al., 2023)

2.5 Ekstraksi Fitur

Fitur yang digunakan sebagai parameter klasifikasi pada penelitian ini adalah *Average of NN intervals* (AVNN) dan *Standard Deviation of NN intervals* (SDNN) dari sinyal PPG yang diakuisisi. AVNN (*Average of NN Intervals*) adalah salah satu metrik yang digunakan dalam analisis HRV untuk deteksi stress dari domain waktu. AVNN mengukur rata-rata interval antara detak jantung yang dianggap normal (NN), yaitu interval yang tidak dipengaruhi oleh aritmia atau gangguan lainnya. Metrik ini memberikan gambaran umum tentang keseimbangan antara aktivitas simpatik dan parasimpatik dalam sistem saraf otonom. Penurunan nilai AVNN biasanya menunjukkan peningkatan aktivitas simpatik atau penurunan aktivitas parasimpatik, yang sering dikaitkan dengan kondisi stres. Sebaliknya, peningkatan AVNN menunjukkan dominasi aktivitas parasimpatik, yang berhubungan dengan keadaan relaksasi. Persamaan matematis untuk menghitung AVNN ditunjukkan pada Persamaan (1), dimana NN_i adalah interval NN ke- i dan N adalah jumlah total interval NN yang dihitung.


$$AVNN = \frac{1}{N} \sum_{i=1}^N NN_i \quad (1)$$

SDNN (*Standard Deviation of NN intervals*) juga merupakan salah satu metrik utama dalam analisis HRV untuk deteksi stress dari domain waktu. SDNN

mengukur variasi total dalam interval NN (jarak antara dua puncak N berturut-turut pada *photoplethysmogram*) selama periode waktu tertentu. Nilai SDNN yang tinggi menunjukkan variabilitas detak jantung yang baik dan fungsi otonom yang sehat, sedangkan nilai yang rendah dapat mengindikasikan stres, kelelahan, atau kondisi kesehatan yang buruk. Persamaan matematis untuk menghitung SDNN ditunjukkan pada Persamaan (2), dimana NN_i adalah interval NN ke- i , adalah rata-rata dari semua interval NN, dan N adalah jumlah total interval NN yang dihitung.

$$SDNN = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (NN_i - \overline{NN})^2} \quad (2)$$

2.6 Decision Tree (DT)



Gambar 5. Metode *Decision Tree* (DT)
Sumber: cloudzilla.ai (2020)

Decision Tree (DT) adalah salah satu metode dalam *machine learning* yang digunakan untuk membangun model prediksi dalam bentuk struktur pohon. Metode ini bekerja dengan memecah dataset menjadi *subset* yang lebih kecil berdasarkan fitur-fitur tertentu, hingga mencapai keputusan akhir yang dapat digunakan untuk klasifikasi atau regresi. Setiap *node* dalam pohon mewakili fitur dari dataset, setiap cabang mewakili aturan keputusan, dan setiap daun mewakili hasil atau label kelas. Proses pembentukan pohon dimulai dari *root node*, yang berisi seluruh dataset, dan secara iteratif membagi dataset berdasarkan fitur yang memberikan pemisahan terbaik, biasanya diukur dengan metrik seperti *Gini impurity* atau *entropy*. *Gini Impurity* untuk dataset S dengan n kelas dihitung sesuai Persamaan (3) dimana p_i adalah probabilitas dari kelas i dalam dataset S . Salah satu keunggulan utama dari *Decision Tree* adalah kemampuannya untuk menangani data yang bersifat nonlinear dan interaksi antar fitur. Selain itu, model ini mudah diinterpretasikan karena hasilnya dapat divisualisasikan dalam bentuk pohon yang intuitif. Namun, *Decision Tree* juga memiliki kelemahan, seperti kecenderungan untuk *overfitting*, terutama jika pohon terlalu dalam atau kompleks. Untuk mengatasi masalah ini, digunakan teknik *pruning*, yang mengurangi ukuran pohon dengan

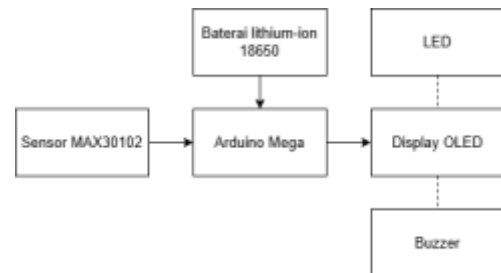
menghapus cabang yang memberikan kontribusi kecil terhadap akurasi model (Razak, 2023).

$$Entropy(S) = - \sum_{i=1}^n p_i \log_2(p_i) \quad (3)$$

3. PERANCANGAN DAN IMPLEMENTASI SISTEM

3.1. Perancangan Perangkat Keras


Blok diagram perancangan perangkat keras dapat dilihat pada Gambar 6.




Gambar 6. Blok Diagram Perancangan Perangkat Keras

Gambar 6 menunjukkan perangkat keras yang digunakan pada sistem ini. Pada bagian input menggunakan Sensor MAX30102 sebagai pengambilan sinyal PPG dan dikirim ke Arduino Mega dengan Baterai lithium-ion 18650 sebagai *power supply*-nya. Arduino Mega mengolah sinyal PPG yang didapat sampai menjadi hasil deteksi stres dan ditampilkan pada layar OLED serta indikator LED warna merah dan buzzer akan menyala apabila menunjukkan kondisi stres. Sedangkan LED hijau akan menyala apabila menunjukkan kondisi tidak stres.

Perancangan perangkat keras terdiri dari perancangan prototipe dan skematik perangkat keras. Perancangan prototipe pada sistem ini adalah desain *case* perangkat keras berbahan dasar filamen yang dibuat menggunakan *software* Fusion 360. Desain *case* disesuaikan dengan perangkat keras yang digunakan dan dicetak dengan 3D Printer. Sedangkan Perancangan skematik perangkat keras adalah proses menggambar diagram rangkaian elektronik yang menunjukkan bagaimana berbagai komponen elektronik seperti sensor, layar OLED, buzzer, LED, dan mikrokontroler terhubung. Perancangan prototipe dan skematik perangkat keras dapat dilihat pada Gambar 7(a) dan Gambar 7(b).



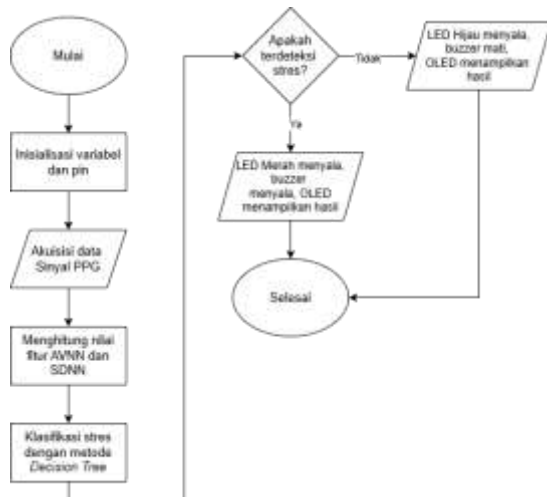
Gambar 7(a). Perancangan Prototipe



Gambar 7(b). Perancangan Skematik Perangkat Keras

3.2. Perancangan Perangkat Lunak

Perancangan perangkat lunak bertujuan untuk membantu menciptakan sistem yang mampu mengolah data agar menghasilkan output yang sesuai dengan tujuan penelitian. Perangkat lunak dirancang untuk mengimplementasikan algoritma atau model *machine learning* yang dilatih, seperti *Decision Tree*. Selanjutnya model *Decision Tree* ini akan diunggah ke dalam Arduino Mega 2560 untuk memproses data sinyal PPG yang dihasilkan dari Sensor MAX30102. Perancangan perangkat lunak digambarkan dalam *flowchart* seperti pada Gambar 8.



Gambar 8. Perancangan Perangkat Lunak

Proses awal dari sistem ini adalah akuisisi data dengan perekaman sinyal PPG menggunakan sensor MAX30102 yang akan memberikan informasi berupa aktivitas detak jantung (*heart rate*). Hasil perekaman sinyal tersebut kemudian dilakukan ekstraksi fitur AVNN dan SDNN yang akan digunakan dalam klasifikasi stres menggunakan metode *Decision Tree* dari data latih. Apabila hasil dari klasifikasi tersebut menunjukkan bahwa terdeteksi stres, maka sistem akan menyalakan LED berwarna merah dan buzzer,


sedangkan jika tidak terdeteksi stres, maka sistem hanya akan menyalakan LED berwarna hijau. Data nilai fitur AVNN dan SDNN, serta status deteksi stres juga akan ditampilkan pada OLED.

3.3 Implementasi Perangkat Keras

Implementasi perangkat keras terdiri dari implementasi prototipe dan skematik perangkat keras. Hasil implementasi prototipe mengikuti rancangan sebelumnya yang telah dibuat menggunakan *Software Fusion360* dicetak dalam bentuk *case* sistem menggunakan 3D Printer. Implementasi skematik perangkat keras dibuat dengan menyesuaikan rangkaian pada perancangan skematik perangkat keras. Semua komponen yang telah dirancang dirangkai menjadi satu kesatuan komponen yang terhubung dengan mikrokontroler. Implementasi prototipe dan skematik perangkat keras dapat dilihat pada Gambar 9(a) dan Gambar 9(b).



Gambar 9(a). Implementasi Prototipe



Gambar 9(b). Implementasi Skematik Perangkat Keras

3.4 Implementasi Perangkat Lunak

Implementasi perangkat lunak merupakan lanjutan dari proses perancangan perangkat lunak. Bagian ini mengintegrasikan dan menguji komponen fisik dalam suatu sistem untuk memastikan perangkat lunak yang sudah dirancang berjalan dengan baik sesuai fungsinya dan terintegrasi baik dengan perangkat keras. Model data latih sebagai masukan untuk metode *Decision Tree* ditunjukkan pada Tabel 1.

Tabel 1. Contoh Data Latih Didapat dari PhysioNet

AVNN (ms)	SDNN (ms)	Label
-----------	-----------	-------

858,35	222,48	TIDAK STRES
789,68	189,98	TIDAK STRES
684,93	29,15	STRES
816,62	224,84	TIDAK STRES
635,17	35,59	STRES
...

Dari data latih tersebut digunakan sebagai masukan metode *Decision Tree* untuk klasifikasi stres pada pengemudi menggunakan Arduino IDE yang digambarkan sebagai implementasi perangkat lunak seperti pada Gambar 10.

```


Output Serial Monitor x
Message (Enter to send message to Arduino Mega)

AVNN: 877.16 ms
SDNN: 121.83 ms
Computation Time: 1 s
Status: Tidak Stress
AVNN: 870.84 ms
SDNN: 124.21 ms
Computation Time: 2 s
Status: Tidak Stress
AVNN: 870.92 ms
SDNN: 124.59 ms
Computation Time: 1 s
Status: Tidak Stress
AVNN: 871.05 ms
SDNN: 123.02 ms
Computation Time: 1 s
Status: Tidak Stress
AVNN: 869.22 ms
SDNN: 122.06 ms
Computation Time: 2 s
Status: Tidak Stress

```

Gambar 10. Implementasi Perangkat Lunak

Implementasi model *Decision Tree* yang sudah dilatih menggunakan Software MATLAB pada bagian *Classification Learner* ditunjukkan pada Gambar 11.



Gambar 11. Hasil *Classification Tree*: a) Fitur AVNN b) Fitur SDNN


Implementasi perangkat lunak dalam bentuk nilai akurasi dan confusion dari metode *Decision Tree* pada sistem ini benar ditunjukkan pada Gambar 12(a) dan 12(b). Berdasarkan *Confusion Matrix* ini, model memiliki performa yang sangat baik, karena tidak ada kesalahan prediksi (FP yang berada di kuadran kanan atas dan FN yang berada di kuadran kiri bawah bernilai 0). Model ini memiliki akurasi 100% untuk dataset yang diberikan, karena semua prediksi benar.

```

Installing collected packages: m2cgen
Successfully installed m2cgen-0.10.0
Akurasi Model Decision Tree: 100.00%

```


Gambar 12(a). Akurasi Metode *Decision Tree*



Gambar 12(b). *Confusion Matrix* Metode *Decision Tree*

4. HASIL DAN PEMBAHASAN

Hasil didapatkan dari 4 pengujian yang telah dilakukan, yaitu pengujian akurasi sistem dalam mendeteksi NN interval, pengujian kesesuaian pembacaan sinyal PPG menggunakan sensor MAX30102, pengujian akurasi sistem dalam mendeteksi stres, dan pengujian waktu komputasi sistem. Pengujian terhadap akurasi sistem dalam deteksi NN interval dilakukan untuk mengetahui nilai akurasi sistem dengan mengamati, mencatat, dan membandingkan hasil deteksi *heart rate* NN Interval yang diperoleh sistem dengan nilai *heart rate* pada sistem. Hasil sebenarnya adalah dari NN Interval yang diperoleh bernilai sama dengan *heart rate* sistem. Pengujian ini dilakukan kepada 5 subjek dimana tiap subjek melakukan percobaan 2 kali sehingga terdapat total data sebanyak 10. Hasil pengujian dapat dilihat pada Gambar 13 dan Tabel 2.



Gambar 13. Hasil Pengujian Deteksi NN interval

Tabel 2. Hasil Pengujian Akurasi Deteksi NN interval

Partisipan	Percobaan ke-	Heart Rate NN interval	Heart Rate Sistem	Error Rate
1	1	89,53	89,6	0,07%
	2	89,64	89,83	0,21%
2	1	88,08	88	0,09%
	2	86,48	86,33	0,17%
3	1	76,20	76,16	0,05%
	2	81,01	81,33	0,39%

4	1	91,27	91,4	0,14%
	2	91,39	91,16	0,25%
5	1	84,6	84,6	0%
	2	81,77	81,66	0,13%
Mean Absolute Percentage Error (MAPE)				0,15%

$$\begin{aligned} \text{Akurasi} &= 100\% - \text{MAPE} \\ &= 100\% - 0,15\% \\ &= 99,85\% \end{aligned} \quad (4)$$

Hasil pengujian ini menghitung nilai akurasi yang diperoleh sesuai pada persamaan 4. Nilai *error rate* diperoleh dari selisih *heart rate* NN interval dan sistem yang dibagi dengan nilai *heart rate* NN interval kemudian dikali 100 untuk mendapatkan persentasenya. Nilai akurasi dari sistem untuk mendeteksi NN Interval dalam mengukur detak jantung adalah 99,85%. Hal ini menunjukkan bahwa sistem memiliki nilai akurasi yang tinggi sehingga memenuhi aspek keandalan untuk perangkat deteksi stres berdasarkan detak jantung.

Pengujian kesesuaian pembacaan sinyal PPG menggunakan sensor MAX30102 dilakukan untuk mengetahui kesesuaian pembacaan sensor MAX30102 dalam merekam aktivitas detak jantung melalui jari berupa sinyal PPG yang digunakan sebagai dasar dalam sistem deteksi stres. Pengujian ini dilakukan dengan membandingkan *heart rate* pada sistem dengan *heart rate* manual. Hasil pengujian ini dapat dilihat pada Tabel 3.

Tabel 3. Hasil Pengujian Pembacaan Sinyal PPG

Partisipan	Percobaan ke-	Heart Rate Sistem	Heart Rate Manual	Error Rate
1	1	89,6	87,6	2,28%
	2	89,8	93	3,44%
2	1	88	86	2,32%
	2	86,3	86	0,34%
3	1	76,1	78	2,43%
	2	81,3	84	3,21%
4	1	91,4	93,6	2,35%
	2	91,1	93	2,04%
5	1	84,6	85	0,47%
	2	81,6	85	4,16%
Mean Absolute Percentage Error (MAPE)				0,15%

Hasil pengukuran *heart rate* baik oleh sistem maupun manual bervariasi untuk semua partisipan. Nilai *error rate* diperoleh dari selisih *heart rate* sistem dan manual yang dibagi dengan nilai *heart rate* manual kemudian dikali 100 untuk mendapatkan persentasenya. Dari nilai *heart rate* sistem dan manual di atas, diperoleh *error rate* untuk masing-masing percobaan yang menunjukkan angka di bawah 5%. Setelah mengetahui nilai *error rate* untuk masing-masing percobaan dihitung rata-ratanya sehingga didapatkan nilai *Mean Absolute Percentage Error* (MAPE) sebesar 2,30%. Menurut (An, Al-Fawa'reh and Kang, 2022), Nilai MAPE dibawah 5% dianggap sebagai indikator yang baik untuk akurasi sistem.

Pengujian klasifikasi menggunakan metode *Decision Tree* merupakan proses untuk menunjukan

hasil *testing* dan tingkat akurasi yang didapat dari sistem dalam mendeteksi stres dengan fitur AVNN dan SDNN. Hasil yang diperoleh sistem akan dibandingkan dengan hasil sebenarnya dimana kuesioner DASS-42 digunakan sebagai validator tambahan untuk membuktikan bahwa pengemudi benar-benar merasa stres atau sebaliknya. Hasil pengujian dapat dilihat pada Gambar 14 dan Tabel 4.



Gambar 14. Hasil Pengujian Akurasi Sistem Menggunakan Metode *Decision Tree* Berdasarkan Fitur AVNN dan SDNN: a) kondisi stres, buzzer dan LED merah menyala b) kondisi tidak stres, buzzer mati dan LED hijau menyala.

Tabel 4. Hasil Pengujian Akurasi Sistem Menggunakan Metode *Decision Tree* Berdasarkan Fitur AVNN dan SDNN

Partisipan	Kondisi & Skenario Jalan	Hasil Klasifikasi Sistem	Hasil Klasifikasi Sebenarnya	Keterangan
1	Jalan Tol tanpa Lalu Lintas	Tidak Stres	Tidak Stres	Sesuai
	Jalan Tol dengan Lalu Lintas	Stres	Stres	Sesuai
	Jalan Kota tanpa Lalu Lintas	Tidak Stres	Tidak Stres	Sesuai
	Jalan Kota dengan Lalu Lintas	Stres	Stres	Sesuai
2	Jalan Tol tanpa Lalu Lintas	Stres	Tidak Stres	Tidak Sesuai
	Jalan Tol dengan Lalu Lintas	Stres	Stres	Sesuai
	Jalan Kota tanpa Lalu Lintas	Stres	Tidak Stres	Tidak Sesuai
	Jalan Kota dengan Lalu Lintas	Stres	Stres	Sesuai
3	Jalan Tol tanpa Lalu Lintas	Tidak Stres	Tidak Stres	Sesuai
	Jalan Tol dengan Lalu Lintas	Stres	Stres	Sesuai

	Jalan Kota tanpa Lalu Lintas	Tidak Stres	Tidak Stres	Sesuai
	Jalan Kota dengan Lalu Lintas	Stres	Stres	Sesuai
4	Jalan Tol tanpa Lalu Lintas	Tidak Stres	Tidak Stres	Sesuai
	Jalan Tol dengan Lalu Lintas	Stres	Stres	Sesuai
	Jalan Kota tanpa Lalu Lintas	Stres	Tidak Stres	Tidak Sesuai
	Jalan Kota dengan Lalu Lintas	Stres	Stres	Sesuai
5	Jalan Tol tanpa Lalu Lintas	Stres	Tidak Stres	Tidak Sesuai
	Jalan Tol dengan Lalu Lintas	Stres	Stres	Sesuai
	Jalan Kota tanpa Lalu Lintas	Tidak Stres	Tidak Stres	Sesuai
	Jalan Kota dengan Lalu Lintas	Stres	Stres	Sesuai

Perhitungan akurasi sistem pada sistem deteksi stres menggunakan validasi kuesioner DASS-42 dapat dilakukan dengan menggunakan Persamaan 5.

$$Akurasi = \frac{Data\ sesuai}{Total\ data} \times 100\% \quad (5)$$

$$Akurasi = \frac{16}{20} \times 100\%$$

$$Akurasi = 0,8 \times 100\%$$

$$Akurasi = 80\%$$

Hasil pengujian akurasi sistem ini dihitung dengan cara membandingkan banyaknya jumlah kesesuaian hasil sistem dengan hasil sebenarnya, kemudian dibagi dengan total data dan dikali 100%. Nilai akurasi sistem dengan metode klasifikasi *Decision Tree* berdasarkan fitur AVNN dan SDNN adalah 80%. Hal ini menunjukkan bahwa sistem ini memiliki nilai akurasi yang cukup baik sehingga memenuhi aspek keandalan untuk perangkat portabel.

Pengujian waktu komputasi sistem dilakukan dengan menghitung waktu komputasi sistem untuk melakukan satu kali *loop program* (dalam detik) untuk mendeteksi stres hingga menampilkan hasilnya di layar OLED dan mengaktifkan indikator LED serta buzzer. Pengujian ini melibatkan perekaman data dari 5 subjek pada tiap kondisi dan skenario jalan. Hasil pengujian dapat dilihat pada Tabel 5.

Tabel 5. Hasil Pengujian Waktu Komputasi Sistem

Partisipan	Kondisi & Skenario	Waktu
------------	--------------------	-------

	Jalan	Komputasi (s)
1	Jalan Tol tanpa Lalu Lintas	3
	Jalan Tol dengan Lalu Lintas	4
	Jalan Kota tanpa Lalu Lintas	3
	Jalan Kota dengan Lalu Lintas	2
2	Jalan Tol tanpa Lalu Lintas	3
	Jalan Tol dengan Lalu Lintas	1
	Jalan Kota tanpa Lalu Lintas	3
	Jalan Kota dengan Lalu Lintas	1
3	Jalan Tol tanpa Lalu Lintas	4
	Jalan Tol dengan Lalu Lintas	3
	Jalan Kota tanpa Lalu Lintas	2
	Jalan Kota dengan Lalu Lintas	2
4	Jalan Tol tanpa Lalu Lintas	3
	Jalan Tol dengan Lalu Lintas	4
	Jalan Kota tanpa Lalu Lintas	2
	Jalan Kota dengan Lalu Lintas	3
5	Jalan Tol tanpa Lalu Lintas	1
	Jalan Tol dengan Lalu Lintas	2
	Jalan Kota tanpa Lalu Lintas	3
	Jalan Kota dengan Lalu Lintas	3
	Rata-rata	2,6

Perhitungan rata-rata waktu komputasi pada 5 subjek dengan total 20 data untuk mendapatkan hasilnya menggunakan rumus pada Persamaan 6.

$$Rata - rata\ waktu\ komputasi = \frac{Total\ waktu}{Total\ data} \quad (6)$$

$$Rata - rata\ waktu\ komputasi = \frac{52}{20}$$

$$Rata - rata\ waktu\ komputasi = 2,6\ detik$$

Berdasarkan hasil dan analisis pengujian waktu komputasi yang dilakukan oleh sistem untuk deteksi stres pada Tabel 5, diperoleh hasil rata-rata waktu 2,6 detik untuk setiap datanya. Pengujian ini membuktikan bahwa waktu komputasi sistem cepat dalam mendeteksi stres sehingga sistem ini efisien untuk perangkat portabel.

5. KESIMPULAN

Penelitian Implementasi *Decision Tree* untuk Sistem Deteksi Stres pada Pengemudi Berbasis Sinyal *Photoplethysmogram* memberikan kesimpulan dari pengujian yang telah dilakukan antara lain: Sistem dapat mendeteksi NN Interval dalam mengukur detak jantung dengan sangat baik. Bukti menunjukkan bahwa nilai *heart rate* berdasarkan NN Interval yang diperoleh dan nilai

heart rate yang ditampilkan pada serial monitor memiliki kesamaan sangat mirip dengan akurasi 99,58%. Pembacaan sinyal PPG menggunakan sensor MAX30102 menunjukkan kesesuaian yang baik. Pengujian yang membandingkan heart rate sistem dengan heart rate manual menunjukkan nilai *Mean Absolute Percentage Error* (MAPE) yang rendah di bawah 5%. Hal ini sesuai dengan pernyataan (An, Al-Fawa'reh and Kang, 2022), bahwa Nilai MAPE dibawah 5% dianggap sebagai indikator yang baik untuk akurasi sistem. Pengujian akurasi sistem menggunakan metode *Decision Tree* dalam mendeteksi stres atau tidaknya pengemudi dalam simulasi mengemudi sudah baik. Hal ini ini dibuktikan melalui pengujian klasifikasi pada sistem dan dikuatkan melalui validasi menggunakan kuesioner DASS-42, yang melibatkan 5 subjek pada 4 kondisi dan skenario jalan. Dari pengujian akurasi sistem berhasil mencapai akurasi sebesar 80%. Nilai waktu komputasi sistem deteksi stres pada pengemudi menggunakan metode *Decision Tree* dengan 20 data uji melibatkan 5 subjek pada 4 kondisi dan skenario jalan didapatkan rata-ratanya adalah 2,6 detik.

6. DAFTAR PUSTAKA

- MOU, L., ZHOU, C., ZHAO, P., NAKISA, B., RASTGOO, M. N., JAIN, R., & GAO, W. (2021). Driver stress detection via multimodal fusion using attention-based CNN-LSTM. *Expert Systems with Applications*, 173, 114693.
- BROWN, T. G., OUMET, M. C., ELDEB, M., TREMBLAY, J., VINGILIS, E., NADEAU, L., PRUESSNER, J., BECHARA, A. (2016). Personality, executive control, and neurobiological characteristics associated with different forms of risky driving. *PLOS ONE*, 11(2).
- USECHE, S. A., ORTIZ, V. G., & CENDALES, B. E. (2017). Stress-related psychosocial factors at work, fatigue, and risky driving behavior in bus rapid transport (BRT) drivers. *Accident Analysis & Prevention*, 104, 106–114.
- AYUNINGRUM, F. T. (2023). *Proyeksi Penduduk indonesia 2020-2050: Hasil Sensus Penduduk 2020*. Badan Pusat Statistik.
- ZONTONE, P., AFFANNI, A., PIRAS, A., & RINALDO, R. (2022). Exploring physiological signal responses to traffic-related stress in simulated driving. *Sensors*, 22(3), 939.
- <https://doi.org/10.3390/s22030939>
- ASHWIN, V.H., JEGAN, R., & RAJALAKSHMY, P. (2022). Stress Detection using Wearable Physiological Sensors and Machine Learning Algorithm. *Proceedings of the Sixth International Conference on Electronics, Communication and Aerospace Technology (ICECA 2022)*.
- DALMEIDA, K.M., MASALA, G.L. (2021). HRV Features as Viable Physiological Markers for Stress Detection Using Wearable Devices. *Sensors*, 21(8), 2873.
- DOBBS, W. C., FEDEWA, M. V., MACDONALD, H. V., HOLMES, C. J., CICONE, Z. S., PLEWS, D. J., & ESCO, M. R. (2019). The accuracy of acquiring heart rate variability from portable devices: A systematic review and meta-analysis. *Sports Medicine*, 49(3), 417–435.
- VALENTI, S., VOLPES, G., PARISI, A., PERI, D., LEE, J., FAES, L., BUSACCA, A., & PERNICE, R. (2023). Wearable multisensor ring-shaped probe for assessing stress and Blood Oxygenation: Design and preliminary measurements. *Biosensors*, 13(4), 460.
- BARKI, H., CHUNG, WY. (2023). Mental Stress Detection Using a Wearable In-Ear Plethysmography. *Biosensors*, 13(3), 397.
- ZAINUDIN, Z., HASAN, S., SHAMSUDDIN, S. M., & ARGAWAL, S. (2021). Stress detection using machine learning and Deep Learning. *Journal of Physics: Conference Series*, 1997(1), 012019
- ABDUL RAZAK, S. F., SAYED ISMAIL, S. N., YOGARAYAN, S., AZLI ABDULLAH, M. F., KAMIS, N. H., & ABDUL AZIZ, A. (2023). Comparative study of machine learning algorithms in classifying HRV for the driver's physiological condition. *Civil Engineering Journal*, 9(9), 2272–2285.
- MUNLA, N., KHALIL, M., SHAHIN, A., & MOURAD, A. (2015). Driver stress level detection using HRV analysis. *2015 International Conference on Advances in Biomedical Engineering (ICABME)*.
- LIU, S.-H., LI, R.-X., WANG, J.-J., CHEN, W., & SU, C.-H. (2020). Classification of photoplethysmographic signal quality

- with deep convolution neural networks for accurate measurement of cardiac stroke volume. *Applied Sciences*, 10(13), 4612.
<https://doi.org/10.3390/app10134612>.
- ESGALHADO, F., BATISTA, A., VASSILENKO, V., RUSSO, S., & ORTIGUEIRA, M. (2022). Peak detection and HRV feature evaluation on ECG and PPG Signals. *Symmetry*, 14(6), 1139.
- NATH, R. K., THAPLIYAL, H., & CABAN-HOLT, A. (2018). Towards photoplethysmogram based non-invasive blood pressure classification. *2018 IEEE International Symposium on Smart Electronic Systems (iSES) (Formerly iNiS)*, 37–39.
- GERVASI, R., CAPPONI, M., MASTROGIACOMO, L., & FRANCESCHINI, F. (2023). Manual Assembly and human–robot collaboration in Repetitive Assembly Processes: A structured comparison based on human-centered performances. *The International Journal of Advanced Manufacturing Technology*, 126(3–4), 1213–1231.
- KIM, H.-G., CHEON, E.-J., BAI, D.-S., LEE, Y. H., & KOO, B.-H. (2018). Stress and heart rate variability: A meta-analysis and review of the literature. *Psychiatry Investigation*, 15(3), 235–245.
- PEREIRA, T., ALMEIDA, P. R., CUNHA, J. P. S., & AGUIAR, A. (2017). Heart rate variability metrics for fine-grained stress level assessment. *Computer Methods and Programs in Biomedicine*, 148, 71–80.
- HEALEY, J. A., & PICARD, R. W. (2005). Detecting stress during real-world driving tasks using physiological sensors. *IEEE Transactions on Intelligent Transportation Systems*, 6(2), 156–166.
- AN, A., AL-FAWA'REH, M., & KANG, J. J. (2022). Enhanced heart rate prediction model using damped least-squares algorithm. *Sensors*, 22(24), 9679.